

### 2.6 DISTRIBUCIÓN HIPERGEOMÉTRICA Y DISTRIBUCIÓN DE POISSON.

Supón ahora que tenemos una población con  $r$  objetos, de los cuales  $r_1$  son del tipo A y  $r_2$  del tipo B. Entonces el número de objetos en la población es  $r = r_1 + r_2$ . Se toma una muestra aleatoria sin reemplazo de tamaño  $n$ , menor o igual a  $r$ , siendo de interés la v.a.  $X$ : número de objetos del tipo A en la muestra.

Esta v.a se conoce como **hipergeométrica**. Observa que el valor de la v.a no puede ser mayor que  $n$  ni mayor que  $r_1$  es decir  $x \leq \min(r_1, n)$ .

#### Ejemplos:

- i)  $n = 10$  muestra de tamaño 10.  
 $r_1 = 5$  en la población hay 5 objetos del tipo A.  
 El número de objetos del tipo A **en la muestra** a lo más es 5 que es precisamente  $r_1$ .
- ii)  $n = 6$  muestra de tamaño 6.  
 $r_1 = 7$  en la población hay 7 objetos del tipo A.  
 El número de objetos del tipo A en la muestra a lo más es 6 que es precisamente el tamaño de la muestra  $n$ .

De igual manera el número de objetos del tipo B en la muestra,  $n - x$ , no puede exceder al número total de objetos del tipo B en la población, es decir,  $n - x \leq r_2 \Rightarrow n - r_2 \leq x$  y tampoco puede ser un número negativo por lo tanto  $\max(0, n - r_2) \leq x \leq \min(r_1, n)$ .

#### Ejemplos:

- i)  $n = 10$  muestra de tamaño 10.  
 $r_1 = 5$  en la población hay 5 objetos del tipo A.  
 El número de objetos del tipo A en la muestra a lo más es 5 que es precisamente  $r_1$ .
- ii)  $n = 6$  muestra de tamaño 6.  
 $r_1 = 7$  en la población hay 7 objetos del tipo A.  
 El número de objetos del tipo A en la muestra a lo más es 6 que es precisamente el tamaño de la muestra  $n$ .
- De igual manera el número de objetos del tipo B en la muestra,  $n - x$ , no puede exceder al número total de objetos del tipo B en la población, es decir,  $n - x \leq r_2 \Rightarrow n - r_2 \leq x$  y tampoco puede ser un número negativo por lo tanto  $\max(0, n - r_2) \leq x \leq \min(r_1, n)$ .

#### Ejemplos:

- i)  $n = 6$  muestra de tamaño 6.  
 $r_1 = 7$  en la población hay 7 objetos del tipo A.  
 $r_2 = 5$  y 5 objetos del tipo B, entonces el número total de elementos en la población es  $r = 12$ .  
 La variable aleatoria de interés toma valores entre 1 y 6 inclusive, ya que  $\max(0, 6 - 5) \leq x \leq \min(7, 6)$ .
- ii)  $n = 6$  muestra de tamaño 6.  
 $r_1 = 5$  en la población hay 5 objetos del tipo A.  
 $r_2 = 10$  elementos del tipo B, entonces el número total de elementos en la población es  $r = 15$ .  
 La variable aleatoria de interés toma valores entre 0 y 5 inclusive, ya que  $\max(0, 6 - 10) \leq x \leq \min(5, 6)$ .
- Si tomamos una muestra aleatoria de tamaño 6, el mínimo número de objetos de la clase A es cero (hay 10 objetos de la clase B, entonces los 6 de la muestra pueden ser de este tipo) y el máximo número posible es 5 ya que sólo hay 5 del tipo A en la población.

**Función de probabilidad.**  
 La expresión  $X \sim H(x; r_1, r_2, n)$  indica que la variable aleatoria  $X$  tiene una distribución hipergeométrica con parámetros  $r_1, r_2$  y  $n$ , tal distribución es de la forma:

$$f_X(x) = \frac{\binom{r_1}{x} \binom{r_2}{n-x}}{\binom{r}{n}} \quad \max(0, n-r_1) \leq x \leq \min(r_1, n) \quad r = r_1 + r_2$$

Recordemos que **NO HAY** DEPENDENCIA.

#### Esperanza y varianza.

Sean las variables aleatorias Bernoulli  $X_i = \begin{cases} 1 & \text{si } X_i \text{ es del tipo A} \\ 0 & \text{si } X_i \text{ es del tipo B} \end{cases}$  para  $i = 1, 2, \dots, n$ .

Para las cuales  $E(X_i) = p = \frac{r_1}{r}$ .

Observa que la v.a. hipergeométrica es la suma de estas variables aleatorias Bernoulli,  $X = \sum_{i=1}^n X_i$ , usando las propiedades del valor esperado se tiene que:

$$E(X) = E\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n E(X_i) = nE(X_i)$$

Y así se tiene que la esperanza de la v.a hipergeométrica es:  $E(X) = n \frac{r_1}{r}$

La muestra se toma sin reemplazo, por lo tanto las variables aleatorias  $X_i$  no son independientes. Para encontrar la varianza de la v.a hipergeométrica necesitamos la varianza de cada  $X_i$  y la covarianza  $Cov(X_i, X_j) \forall i < j$ .

$$f_X(x) = \frac{\binom{r_1}{x} \binom{r_2}{n-x}}{\binom{r}{n}} \quad \max(0, n-r_1) \leq x \leq \min(r_1, n) \quad r = r_1 + r_2$$

La varianza de cada Bernoulli es  $V(X_i) = pq = \frac{r_1}{r} \left(1 - \frac{r_1}{r}\right)$

Y la covarianza entre  $X_i$  y  $X_j$  está dada por:

$$Cov(X_i, X_j) = E(X_i X_j) - E(X_i)E(X_j) \quad \forall i < j$$

Los valores posibles que toma el producto son 0 y 1 de la manera siguiente:

$$X_i = 0 \text{ y } X_j = 1 \quad X_i X_j = 0$$

$$X_i = 1 \text{ y } X_j = 0 \quad X_i X_j = 0$$

$$X_i = 0 \text{ y } X_j = 0 \quad X_i X_j = 0$$

$$X_i = 1 \text{ y } X_j = 1 \quad X_i X_j = 1$$

$$E(X_i X_j) = 1 \cdot P(X_i = 1, X_j = 1) = P(X_i = 1)P(X_j = 1) = \frac{r_1}{r} \cdot \frac{r_1 - 1}{r - 1}$$

$$Entonces Cov(X_i, X_j) = \frac{r_1(r_1 - 1)}{r(r - 1)} - \frac{r_1}{r} \cdot \frac{r_1}{r} = \frac{r_1}{r} \left( \frac{r_1 - 1}{r - 1} - \frac{r_1}{r} \right) = \frac{r_1}{r} \left( \frac{r_1 - r}{r(r - 1)} \right) = \frac{r_1}{r} \left( \frac{r_1 - r}{r(r - 1)} \right) \quad (2)$$

Usando las ecuaciones (1) y (2) en la expresión de la varianza:

$$V(X) = V\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n V(X_i) + 2 \sum_{i < j} Cov(X_i, X_j)$$

$$= n \frac{r_1}{r} \left(1 - \frac{r_1}{r}\right) + 2 \sum_{i < j} \frac{r_1}{r} \left( \frac{r_1 - r}{r(r - 1)} \right)$$

$$= n \frac{r_1}{r} \left(1 - \frac{r_1}{r}\right) + n(n-1) \frac{r_1}{r} \left( \frac{r_1 - r}{r(r - 1)} \right)$$

$$= n \frac{r_1}{r} \left( \frac{r - r_1}{r} \right) - n \frac{r_1}{r} \left( \frac{r - r_1}{r} \right) \frac{n-1}{r-1}$$

$$= n \frac{r_1}{r} \left( \frac{r - r_1}{r} \right) \left(1 - \frac{n-1}{r-1}\right)$$

Finalmente tenemos que la varianza de la v.a hipergeométrica está dada por:

$$V(X) = n \frac{r_1}{r} \left(1 - \frac{r_1}{r}\right) \left(1 - \frac{n-1}{r-1}\right)$$

**Nota.** Supón que se tiene una población de tamaño  $r$  con  $r_1$  objetos de la clase A y  $r - r_1$  de la clase B, y se toma una muestra aleatoria (m.a) de tamaño  $n$ . La v.a  $Y$ : Número de objetos de la clase A en la muestra puede tener dos distribuciones de probabilidad diferentes, dependiendo de la manera en que se toma la m.a.

i) Si la muestra se toma **con reemplazo**, la probabilidad de éxito (el objeto es de la clase A) es constante igual a  $\frac{r_1}{r}$ , hay independencia y por lo tanto  $Y \sim b(y; n, p)$  con  $E(X) = np = n \frac{r_1}{r}$  y

$$V(Y) = npq = n \frac{r_1}{r} \left(1 - \frac{r_1}{r}\right)$$

ii) Si la muestra se toma sin reemplazo entonces  $Y \sim H(y; r_1, r_2, n)$  con  $E(Y) = np = n \frac{r_1}{r}$  y

$$V(Y) = n \frac{r_1}{r} \left(1 - \frac{r_1}{r}\right) \left(1 - \frac{n-1}{r-1}\right)$$

El valor esperado es el mismo pero si el muestreo es sin reemplazo la varianza es menor ya que:

$$n \frac{r_1}{r} \left(1 - \frac{r_1}{r}\right) > n \frac{r_1}{r} \left(1 - \frac{r_1}{r}\right) \left(1 - \frac{n-1}{r-1}\right)$$

pero  $1 > 1 - \frac{n-1}{r-1}$

Si  $r$  es grande comparado con  $n$ , entonces  $\frac{n}{r} \rightarrow 0$  y la varianza de la hipergeométrica se parece mucho a la varianza de la binomial, es decir para  $n$  fijo y  $r$  grande (poblaciones muy grandes) hay poca diferencia entre muestreo con y sin reemplazo (binomial e hipergeométrica).

### Función de probabilidad acumulada.

Existen en escuelas del IPN tablas de la distribución acumulada realizadas por los profesores, pero en los libros difícilmente se encontrarán debido a la diversidad de casos, en general esta probabilidad se puede encontrar usando la definición de acumulada y la f.d.p de la Hipergeométrica como sigue:

$$F_X(x) = P(X \leq x) = \sum_{i=\max(0, r_1-n)}^x \frac{\binom{r_1}{i} \binom{r_2}{n-i}}{\binom{r}{n}}$$

#### Ejemplos:

1. Supón que una urna contiene cinco bolas rojas y diez azules. Si se seleccionan al azar **sin reemplazo** siete bolas.

a) ¿Cuál es la probabilidad de obtener al menos tres bolas rojas?

b) Si  $\bar{X}$  representa la proporción de **bolas rojas** en la muestra ¿Cuáles son la media y la varianza de  $\bar{X}$ .

#### Solución

$r_1 = 5$  bolas rojas.  
 $r_2 = 10$  bolas azules.  
 $n = 7$  tamaño de la muestra.  
 $r = 15$  total de bolas en la urna.  
 $X$ : Número de bolas rojas en la muestra.  
 $X \sim H(x; r_1 = 5, r_2 = 10, n = 7)$

$$P(X \geq 3) = P(X = 3) + P(X = 4) + P(X = 5)$$

$$= \frac{\binom{5}{3} \binom{10}{4}}{\binom{15}{7}} + \frac{\binom{5}{4} \binom{10}{3}}{\binom{15}{7}} + \frac{\binom{5}{5} \binom{10}{2}}{\binom{15}{7}} = \frac{2100 + 600 + 45}{6435} = \frac{2745}{6435} = \frac{61}{143} \approx 0.4265$$

b) Observa que  $\bar{X} = \frac{X}{n}$  por lo tanto  $E(\bar{X}) = E\left(\frac{X}{n}\right) = \frac{1}{n} E(X)$  y  $V(\bar{X}) = V\left(\frac{X}{n}\right) = \frac{1}{n^2} V(X)$

$$E(\bar{X}) = \frac{1}{7} \left(\frac{5}{15}\right) = \frac{1}{3} \quad V(\bar{X}) = \frac{1}{7^2} \left(\frac{5}{15}\right) \left(1 - \frac{5}{15}\right) \left(1 - \frac{6}{14}\right) = \frac{1980}{7(3)(15)(14)} = \frac{8}{441} \approx 0.018$$

$$V(\bar{X}) = \frac{1}{7^2} \left(\frac{5}{15}\right) \left(1 - \frac{5}{15}\right) \left(1 - \frac{6}{14}\right) = \frac{1980}{7(3)(15)(14)} = \frac{8}{441} \approx 0.018$$

2. En un almacén se tienen 10 impresoras de las cuales 4 son defectuosas. Una compañía selecciona 5 de las máquinas al azar.

a) ¿Cuál es la probabilidad de que las 5 máquinas sean no defectuosas?

b) La compañía repara las impresoras defectuosas a un costo de 50 dólares cada una. Encuentra la media y la varianza del costo total de reparación.

#### Solución

$r_1 = 6$  máquinas buenas.  
 $r_2 = 4$  máquinas defectuosas.  
 $n = 5$  tamaño de la muestra.  
 $r = 10$  total de máquinas.

$X$ : Número de máquinas buenas en la muestra.

$$X \sim H(x; r_1 = 6, r_2 = 4, n = 5)$$

$$a) P(X = 5) = \frac{\binom{6}{5} \binom{4}{0}}{\binom{10}{5}} = \frac{6}{252} = \frac{1}{42} \approx 0.024$$

b) Ahora sea la v.a de interés  $Y$ : Número de máquinas defectuosas en la muestra.

$$Y \sim H(y; r_1 = 4, r_2 = 6, n = 5)$$

El costo de reparación está dado como  $C(Y) = 50Y$ .

$$Por lo tanto: E(C(Y)) = 50E(Y) = 50(5) \frac{4}{10} = 100$$

$$V(C(Y)) = (50)^2 V(Y) = (50)^2 (5) \left(\frac{4}{10}\right) \left(1 - \frac{4}{10}\right) \left(1 - \frac{4}{9}\right) = 1.666.66$$

3. Una corporación muestrea sin reemplazo  $n = 3$  empresas para adquirir ciertos suministros. La muestra se selecciona de un conjunto de 6 empresas, de las cuales cuatro son locales y dos no lo son.

Sea  $Y$  el número de empresas foráneas entre las tres escogidas. Encuentra las siguientes probabilidades:

a)  $P(Y = 1)$

b)  $P(Y \geq 1)$

c)  $P(Y \leq 1)$

**Solución**

$r_1 = 2$  empresas foráneas.  
 $r_2 = 4$  empresas locales.  
 $n = 3$  tamaño de la muestra.  
 $r = 6$  total de empresas.

$Y$ : Número de empresas foráneas.  
 $Y \sim H(y; r_1 = 2, r_2 = 4, n = 3)$

$$a) P(Y = 1) = \frac{\binom{2}{1} \binom{4}{2}}{\binom{6}{3}} = \frac{3}{5} = 0.6$$

$$b) P(Y \geq 1) = 1 - P(Y = 0) = 1 - \frac{\binom{2}{0} \binom{4}{3}}{\binom{6}{3}} = 1 - \frac{1}{5} = 0.8$$

$$c) P(Y \leq 1) = P(Y = 0) + P(Y = 1) = \frac{1}{5} + \frac{3}{5} = 0.8$$