```
MÉTODO DE LOS MOMENTOS PARA ESTIMAR PARÁMETROS.
        m_k = \frac{1}{n} \sum_{i=1}^n X_i^{\ k} \quad \  \  \, \text{$k$-\'esimo momento muestral de la v.a $X$.}
        \mu_k = m_k y de aquí se despeja el estimador.
     Al estimador del parámetro \theta obtenido por el método de los momentos se le pone una tilde de la forma \bar{\theta} .
     Ejemplo 9: Sea X-N(x,\mu,\sigma^2) estima \theta=(\mu,\sigma^2) en base a una muestra aleatoria de tamaño n usando el método de los momentos.
     Tenemos dos parimetros a estimar por lo tanto necesitamos los dos primeros momentos muestrales y los dos primeros momentos poblacionales. Se igualan los primeros momentos, \overline{\mu} = \overline{z} Se igualan los primeros momentos, \overline{\psi} = \overline{z} Se igualan también los segundos momentos
        \mu_2 = E(X^2) = \sigma^2 + \mu^2 = \frac{1}{n} \sum_{i=1}^n x_i^2 = m_2 entonces \left[\overline{\mu} = \overline{x}\right]
                                                                                                                                                                                                                                                                                                                                                                                                                                  E(8, ) = 4(8) + /42
                                                                                                                                                                                                           \widetilde{\sigma}^2 + \widetilde{\mu}^2 = \frac{1}{n} \sum_{i=1}^{n} x_i^2
                                                                                                                                                                                                        \widetilde{\sigma}^2 + (\widetilde{x})^2 = \frac{1}{n} \sum_{i=1}^n x_i^2
                                                                                                                                                                               \tilde{\sigma}^2 = \frac{1}{n} \sum_{i=1}^{n} x_i^2 - (\bar{x})^2 = \frac{1}{n} \left[ \sum_{i=1}^{n} x_i^2 - n(\bar{x})^2 \right]
                                                                                                                                                                                                                         \vec{\sigma}^2 = \frac{1}{n} \sum_{i=1}^{n} (x_i - \vec{x})^n
                                                                                                                                                                                          \begin{split} \mu_1 &= \frac{\widetilde{\alpha}}{\widetilde{\beta}} = \overline{X} = m_1 \\ \mu_2 &= \frac{\widetilde{\alpha}}{\widetilde{\beta}^2} + \frac{2}{\widetilde{\beta}^2} = \frac{1}{n} \sum_{t=1}^n X_t^2 = m_2 \end{split} 
                                                                                                                                                                                                                                                                                                                                                                                                                                                           S^{\frac{1}{2}} = \frac{\widetilde{\alpha}}{\widetilde{\beta}} = \overline{\lambda} \qquad \angle \cdot \left(\frac{\widetilde{\alpha}}{\widetilde{\beta}}\right)_{\widetilde{\beta}}^{1} + \left(\frac{\widetilde{\alpha}}{\widetilde{\beta}}\right)^{2} = \frac{1}{\widetilde{\alpha}} \cdot \sum_{i=1}^{\widetilde{\alpha}} \chi_{i}^{2}
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                               \frac{\overline{x}}{\widetilde{\beta}'} + \overline{x}^2 = \frac{1}{n} \underbrace{\underset{i=1}{\overset{n}{\approx}} X_i^2}_{i=1}
                                                                                                                                                                                                                      \frac{\overline{\beta} \overline{X}}{\overline{\beta}^2} + \frac{\overline{\beta}^2 \overline{X}^2}{\overline{\beta}^2} = \frac{1}{n} \sum_{i=1}^{n} X_i^2
                                                                                                                                                                                                                               \frac{\overline{X}}{\widetilde{B}} + \overline{X}^2 = \frac{1}{n} \sum_{i=1}^{n} X_i^2
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                              \begin{array}{c} \int\limits_{\widetilde{Y}}^{r} \leq \frac{1}{n} \left[ -\frac{r}{2} \chi_{1}^{2} - \alpha \overline{\chi}^{2} \right] \\ \widetilde{\beta} \leq \frac{1}{n} \left[ -\frac{r}{2} \chi_{1}^{2} - \alpha \overline{\chi}^{2} \right] \\ = \frac{r}{n} \left[ -\frac{r}{2} \chi_{1}^{2} - \alpha \overline{\chi}^{2} \right] \leq \frac{n \overline{\chi}}{2 (\chi_{1} - \chi_{1})^{2}} \end{array}
                                                                                                                                                                                    \frac{\overline{X}}{\overline{\beta}} = \frac{1}{n} \sum_{i=1}^{n} X_i^2 - \overline{X}^2 = \frac{1}{n} \sum_{i=1}^{n} (X_i^2 - \overline{X})^2
Finalmente, los estimadores por el método de los momentos para los parámetros de la distribución Gamma son. \widetilde{\beta} = \frac{\kappa \widetilde{X}}{\sum_{\underline{n}} \left(X_i^2 - \widetilde{X}\right)^2} y \widetilde{\alpha} = \widetilde{\beta} \widetilde{X} - \frac{\kappa \widetilde{X}^2}{\sum_{\underline{n}} \left(X_i^2 - \widetilde{X}\right)^2}
                                                                                                                                                                         \mu_2 = np(1-p) + n^2p^2 = \frac{1}{k}\sum_{i=1}^k X_i^2 = m_2
                                                                                                                                                                                                   \overline{X}(1-\widetilde{p})+\overline{X}^2=\frac{1}{k}\sum_{i=1}^{k}X_i^2
                                                                                                                                                                                                \overline{X} - \widetilde{p}\overline{X} + \overline{X}^2 = \frac{1}{k}\sum_{i=1}^{k}X_i^2
                                                                                                                                                              \overline{X} - \overline{p}\overline{X} = \frac{1}{k}\sum_{i=1}^{k} X_i^2 - \overline{X}^2 = \frac{1}{k}\sum_{i=1}^{k} (X_i - \overline{X})^2
                                                                                                                                                                                                   \widetilde{p} \, \overline{X} = \overline{X} - \frac{1}{k} \sum_{i=1}^k \left( X_i - \overline{X} \right)^2
                                                                                                                                                                                                   \widetilde{p} = 1 - \frac{1}{k\overline{X}} \sum_{i=1}^{k} (X_i - \overline{X})^2
                                                                                                                                                                                             \widetilde{n} = \frac{\overline{X}}{\widetilde{p}} = \frac{k\overline{X}^2}{k\overline{X} - \sum_{i=1}^{k} (X_i - \overline{X})^2}
     Ejemplo 12: Sea una población con distribución Geométrica con parámetro p. Encuentra el estima
para el parámetro usando el método de los momentos y en base a una muestra aleatoria de tamaño n
\mu_1 = \frac{1}{\widetilde{p}} = \overline{X} = m_1 \therefore \widetilde{p} = \frac{1}{\overline{X}}
METODO BUANNA PARAMETERANO. De l'attribles alentorias se define como su densidud cospinata f_{(x,x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{t-1},x_{
        Recuerda que para maximizar se deriva parcialmente respecto al parámetro de interés, se iguala a cero y se desegie el valor que hace posible la ecuación. Ver facilidad es decidicol y dado que las funciones L(\theta) y ln L(\theta) se maximizan en el miseno punto, se 00 é \log d0.
           Cuando se tiene un vector de parámetros a estimar por ejemplo \theta=(\theta_1,\theta_3,\ldots,\theta_k) la manera de proceder es resolver las k ecuaciones siguientes: \frac{\partial}{\partial \theta_i} \ln L(\theta_i) = \frac{\partial}{\partial \theta_i} \ln L(\theta_i,\theta_3,\ldots,\theta_k) = 0
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                         2) Socor of logarities natural. Lee (16(0))
                                                                                                                                             \frac{\partial}{\partial \theta_2} \ln L(\underline{\theta}) = \frac{\partial}{\partial \theta_2} \ln L(\underline{\theta}_1, \underline{\theta}_2, ..., \underline{\theta}_k) = 0
        f_X(x;p) = p^x(1-p)^{1-x} si x = 0, 1

i) La función de verosimilitud de una m.a de tamaño n
                            Since the logariment natural tensition in the standard of the
        \ln L(p) = \left(\sum_{i=1}^{n} x_i\right) \ln(p) + \left(n - \sum_{i=1}^{n} x_i\right) \ln(1-p)
III) Sacar la derivada parcial respecto a p.
     \frac{\sum_{i=1}^{k} n_i - \sum_{i=1}^{k} n_i - \sum_{i=1}^{k} n_i}{\log n_i} = 0
\frac{\sum_{i=1}^{k} n_i - \sum_{i=1}^{k} n_i}{n_i} = 0
\frac{\sum_{i=1}^{k} n_i}{n_i} = 0
\frac{\sum_{i=1
                                          \frac{\sum_{i=1}^{n} x_i}{\hat{p}} - \frac{n - \sum_{i=1}^{n} x_i}{1 - \hat{p}} = 0
\frac{\sum_{i=1}^{n} x_i}{\hat{p}} = \frac{n - \sum_{i=1}^{n} x_i}{1 - \hat{p}}
                                          \frac{1-\hat{p}}{\hat{p}} = \frac{n - \sum_{i=1}^{n} x_i}{\sum_{i=1}^{n} x_i}
                                    \frac{1}{\hat{p}} - 1 = \frac{n}{\sum_{i=1}^{n} x_i} - 1
```

```
Ejemplo 14: Sea X_1, X_2, \dots, X_s una m.a de una densidad Normal con media \mu y varianza \sigma^2 encuentra el estimador máximo verosímil de \theta = (\mu, \sigma^2).
                                                                                                                                               f_x \Big( x, \mu, \sigma^2 \Big) = \frac{1}{\sigma \sqrt{2\pi}} \, e^{\frac{-1}{2} \left( \frac{x-\mu}{\sigma} \right)^2} \, \text{ si } \, x > 0
                       \theta La función de verosimilitud de una m.a de tamaño n es: L(\mu,\sigma^2) = \prod_{i=1}^n f(\mathbf{x}_i,\mu,\sigma^2) = \prod_{i=1}^n \frac{1}{\sigma \sqrt{2\pi}} e^{-\frac{1}{2}\left(\frac{n-\mu}{\sigma}\right)^2}
                                                                                                              = \left(\sigma \sqrt{2\pi}\right)^{-n} e^{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu)^2}
                          ii) Sacar el logaritmo natural de la función de verosimilitu
                                                           \ln L(\mu, \sigma^2) = -n \ln \sigma - n \ln \sqrt{2\pi} - \frac{1}{2\sigma^2} \sum_{i,i}^{\pi} (x_i - \mu)^2
                          iii) Sacar las derivadas parciales respecto a \mu y respecto a \sigma
\frac{\partial}{\partial \mu} \ln L(\mu, \sigma^2) = \frac{2}{2\sigma^2} \sum_{i=1}^{n} 2(x_i - \mu) = \frac{1}{\sigma^2} \sum_{i=1}^{n} (x_i - \mu)

    iv) Igualar a cero y resolver el sistema para encontrar los estimadores máximo verosímiles de los
parámetros de interés.

                                                        0 = \frac{1}{\sigma^2} \sum_{i=1}^{n} (x_i - \mu) = \frac{1}{\sigma^2} \left[ \sum_{i=1}^{n} x_i - n\hat{\mu} \right] \therefore \underline{\hat{\mu} = x}
                                                        0 = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^4} \sum_{i=1}^{n} (x_i - \mu)^2
                                                        n = \frac{1}{\hat{\sigma}^2} \sum_{i=1}^{n} (x_i - \mu)^2 \therefore \hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^{n} (x_i - \mu)^2
  Substitute

10 La función de verosimilitud está dada por

L(a) = \prod_{i=1}^{n} (E_i, a) = \prod_{i=1}^{n} \frac{1}{a} = \frac{1}{a}

10 Encontrar el valor de a que maximiza la función de verosimilitud.

11 Encontrar el valor de a que maximiza la función de verosimilitud.

12 Encontrar el valor de a que maximiza la función de verosimilitud.

13 Encontrar el valor de a que maximiza la función de verosimilitud.

14 Parecchonolo (a) sen circles el que está el valor más pequeño permitible que está el procedo de la pr
Observa que esta función es máxima cuando a toma el valor más pequebo pernisible que es precisamente la última estadistica de coden, es deciá 2 Xau.

Para el valor de precisamente la última estadistica de coden, es deciá 2 Xau.

Para el valor de precisamente la última estadistica de coden, es deciá 2 Xau.

Para el valor de precisamente la última estadistica de coden, es deciá 2 Xau.

Para el valor de precisamente la última estadistica de coden, es deciá 2 Xau.

Para el valor de precisamente la última estadistica de coden, es deciá 2 Xau.

Para el valor de precisamente la última estadistica de coden, es deciá 2 Xau.

Para el valor de precisamente la última estadistica de coden, es deciá 2 Xau.

Para el valor de precisamente la última estadistica de coden, es deciá 2 Xau.

Para el valor de precisamente la última estadistica de coden, es deciá 2 Xau.

Para el valor de precisamente la última estadistica de coden, es deciá 2 Xau.

Para el valor de precisamente la última estadistica de coden, es deciá 2 Xau.

Para el valor de precisamente la última estadistica de coden, es deciá 2 Xau.

Para el valor de precisamente la última estadistica de coden estados estados
Ejemplo 17: Se torna una muestra aleutoria de turnato n de una población con £d p de Poisson con necia \lambda.

$\frac{1}{\lambda}(1, k) = \frac{\lambda}{\lambda} \lambda \text{ } \frac{\lambda}{\lambda} \text{ } \frac{\lambda}{\la
                                            L(\lambda) = \prod_{i=1}^{n} \frac{\lambda^{s_i} e^{-\lambda}}{x_i!} = e^{-\lambda n} \frac{\sum_{i=1}^{n} x_i}{\prod_{i=1}^{n} x_i!}
                                                  \ln L(\lambda) = -\lambda n + \sum_{i=1}^{n} x_i \ln(\lambda) - \ln \prod_{i=1}^{n} x_i!
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                2) lu(L(X)) = - in +( = X; ) lu(X) + lu(T + )
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                  \frac{3}{2} \sqrt{|Y|(\Gamma(y))} = -V + \frac{5}{2} \chi_{+}^{2} \left(\frac{y}{T}\right) = 0
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                        = \frac{1}{\lambda} \cdot \underbrace{\frac{\alpha}{6}}_{i_1} \chi_i^* - \epsilon \cdot \mathbf{n} \qquad \triangle^{\mathbf{a}} \cdot \overset{\lambda}{\lambda} = \underbrace{+}_{N} \sum_{i_1}^{N} \chi_i^* - \epsilon \cdot \overline{\mathbf{x}} = \overset{\mathbf{a}}{\lambda}
           ii) Igualando a cero y resolviendo se encuentra el estimador máximo verosímil
                                                                                               n = \sum_{i=1}^{n} \frac{x_i}{\lambda} \therefore \hat{\lambda} = \frac{1}{n} \sum_{i=1}^{n} x_i = \overline{x}
        b) Valor esperado y varianza del estimador. E(\overline{X}) = \lambda \ \ y \ \ V(\overline{X}) = \frac{\lambda}{n}
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                        i Es consistente? In V(A) = In A = 0 ~ si es consistente.
           c) \lim_{n\to\infty} V(\overline{X}) = \lim_{n\to\infty} \frac{\lambda}{n} = 0 entonces si es consistente.
        Ejemplo 18: Si X_1X_2...X_n es una muestra alestoria de una población con f.4.p \frac{1}{|N|_{O^{-1}} + 1} \frac{1}{|N
                 verosimil para \theta. \varphi_{\overline{\chi}(x)} = \frac{r}{\theta} \times^{r-1} \exp\left(-\frac{\chi^{\varrho}}{\theta}\right)
           IJ La función de verosimilitud está dada por
                                L(\theta) = \prod_{i=1}^{n} \frac{r}{\theta} x_i^{r-1} e^{-x_i^r/\theta} = \frac{r^a}{\theta^*} e^{-\frac{1}{\theta} \sum_{i=1}^{n} x_i^r} \prod_{j=1}^{n} x_j^{r-1}
              ii) Sacar el logaritmo natural de la función de verosimilitud.
                                      = n \ln(\hat{r}) - n \ln(\theta) - \frac{1}{\theta} \sum_{i=1}^{n} \mathbf{x}_{i}' + (\hat{r} - \hat{r}) \sum_{i=1}^{n} \ln(\mathbf{x}_{i}) + \int_{\mathcal{U}_{i}} \left( \frac{1}{\theta} \sum_{i=1}^{n} \mathbf{x}_{i}' + \hat{r} - \hat{r} \right) d\mathbf{x}_{i}' + \int_{\mathcal{U}_{i}} \left( \frac{1}{\theta} \sum_{i=1}^{n} \mathbf{x}_{i}' + \hat{r} - \hat{r} \right) d\mathbf{x}_{i}' + \int_{\mathcal{U}_{i}} \left( \frac{1}{\theta} \sum_{i=1}^{n} \mathbf{x}_{i}' + \hat{r} - \hat{r} \right) d\mathbf{x}_{i}' + \int_{\mathcal{U}_{i}} \left( \frac{1}{\theta} \sum_{i=1}^{n} \mathbf{x}_{i}' + \hat{r} - \hat{r} \right) d\mathbf{x}_{i}' + \int_{\mathcal{U}_{i}} \left( \frac{1}{\theta} \sum_{i=1}^{n} \mathbf{x}_{i}' + \hat{r} - \hat{r} \right) d\mathbf{x}_{i}' + \int_{\mathcal{U}_{i}} \left( \frac{1}{\theta} \sum_{i=1}^{n} \mathbf{x}_{i}' + \hat{r} - \hat{r} \right) d\mathbf{x}_{i}' + \int_{\mathcal{U}_{i}} \left( \frac{1}{\theta} \sum_{i=1}^{n} \mathbf{x}_{i}' + \hat{r} - \hat{r} - \hat{r} \right) d\mathbf{x}_{i}' + \int_{\mathcal{U}_{i}} \left( \frac{1}{\theta} \sum_{i=1}^{n} \mathbf{x}_{i}' + \hat{r} - \hat{r} - \hat{r} \right) d\mathbf{x}_{i}' + \int_{\mathcal{U}_{i}} \left( \frac{1}{\theta} \sum_{i=1}^{n} \mathbf{x}_{i}' + \hat{r} - \hat{r} - \hat{r} \right) d\mathbf{x}_{i}' + \int_{\mathcal{U}_{i}} \left( \frac{1}{\theta} \sum_{i=1}^{n} \mathbf{x}_{i}' + \hat{r} - \hat{r} - \hat{r} - \hat{r} \right) d\mathbf{x}_{i}' + \int_{\mathcal{U}_{i}} \left( \frac{1}{\theta} \sum_{i=1}^{n} \mathbf{x}_{i}' + \hat{r} - 
                                                  \frac{\partial}{\partial \theta} \ln L(\theta) = -\frac{n}{\theta} + \frac{1}{\theta^2} \sum_{i=1}^{n} x_i^r
              iii) Igualando a cero y resolviendo se tiene que
                                      \frac{n}{\hat{\theta}} = \frac{1}{\hat{\theta}^{2}} \sum_{m}^{\infty} x_{n}^{2} \text{ despejando al estimador del parámetro se tiene que } \underbrace{\hat{\theta} = \begin{bmatrix} 1 & x_{n}^{2} \\ \frac{1}{m} \sum_{m} x_{n}^{2} \end{bmatrix}}_{\substack{C \in Sim n \\ more than \\ more than \\ more than \\ N(s) = X(t)}}_{\substack{C \in Sim n \\ more than \\ N(s) = X(t) \\ N(s) = X(t)}}
Ejemplo 19: Supón que X_1, X_2, \dots, X_n es una ma de la producción per acre de la variedad A de triga, la cual tiene una distribución Normal con media \mu_1 y variante \sigma^2 y que \mathcal{F}_{X_1}, \dots, \mathcal{F}_{X_n} es una ma de la producción per acre de la variedad \rho^2 de triga, la cual su distribuye como una Normal con media \mu_1 y varianta \sigma^2. Si X \perp Y messentra el estimador míximo verosimil para la varianza común \sigma^2 si as desconcom las medias problecionates.
                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                                    |M_F| \approx \frac{1}{4} \sum_{i=1}^{n} |\chi_i|_{g}
La función de verosimilitud para la muestra conjunta está dada por
     L(\mu_1, \mu_2, \sigma^2) = f(X_1, X_2, ..., X_m, Y_1, Y_2, ..., Y_n)
                                                                    = \prod_{i=1}^{n} f(x_i; \mu_1, \sigma^2) \prod_{i=1}^{n} f(y_i; \mu_2, \sigma^2)
                                                           = \prod_{i=1}^{n} \frac{1}{\sigma \sqrt{2\pi}} e^{-\frac{1}{2\sigma^2}(s_i - \mu_i)^2} \prod_{i=1}^{n} \frac{1}{\sigma \sqrt{2\pi}} e^{-\frac{1}{2\sigma^2}(s_i - \mu_i)^2}
                                               = \prod_{i=1}^{n} \frac{\sigma \vee \Delta \pi}{\sigma \sqrt{2\pi}} e^{-\frac{1}{2\sigma^2}(s_i - \mu_i)^2} \prod_{i=1}^{n} \frac{1}{\sigma \sqrt{2\pi}} e^{-\frac{1}{2\sigma^2}(s_i - \mu_i)^2}
                                                           = (2\pi)^{\frac{n+\alpha}{2}} (\sigma^2)^{\frac{n+\alpha}{2}} \exp \left(-\frac{1}{2\sigma^2} \left[ \sum_{i=1}^n (X_i - \mu_i)^2 + \sum_{i=1}^n (Y_i - \mu_2)^2 \right] \right)
  \ln L(\mu_i, \mu_i, \sigma^2) = \ln(2\pi)^{\frac{m+n}{2}} - \frac{m+n}{2} \ln(\sigma^2) - \frac{1}{2\sigma^2} \left[ \sum_{i=1}^n (X_i - \mu_i)^2 + \sum_{i=1}^n (Y_i - \mu_i)^2 \right]
     Derivando parcialmente respecto a la varianza \frac{\partial}{\partial \sigma^2} \ln L(\mu_1, \mu_2, \sigma^2) = -\frac{m+n}{2\sigma^2} + -\frac{1}{2\sigma^4} \left[ \sum_{i=1}^n (X_i - \mu_i)^2 + \sum_{i=1}^n (Y_i - \mu_2)^2 \right]
     \sigma^{2} = \frac{1}{m+n} \left[ \sum_{i=1}^{m} (X_{i} - \overline{X})^{2} + \sum_{i=1}^{n} (Y_{i} - \overline{Y})^{2} \right]
```

Ejemplo 14: Sea $X_1, X_2, ..., X_n$ una m.a de una densidad Normal con media μ y varianza encuentra el estimador máximo verosímil de $\theta = (\mu, \sigma^2)$.